

面向区制切换市场的动作条件流匹配世界模型： 严格恰当的路径分布训练与少步蒸馏

FinFlow 课题组

课程：基于深度学习的内容生成原理与方法

摘要

我们研究面向合成金融市场的生成式世界模型（world model，即一个可被外部智能体的动作驱动、并能自回归推演环境动态的可学习模拟器）。我们要解决的不是“再画一张像收益曲线的图”，而是构造一个同时满足两个苛刻条件的市场模拟器：(i) **可控**——它以一个外部智能体在每一步设定的潜在市场区制（正常/高波动/崩盘）为条件，从而能被“驱动”进入指定情景；(ii) **自洽**——它在自由演化（free-running）地自回归展开整整一年（252 步）时不发散、不漂移，而不是仅在单步教师强制（teacher forcing）下看起来正确。为获得可信的“地面真值”，我们以三区制马尔可夫切换 Heston 过程合成数据，并用一个独立的十万条蒙特卡洛（MC）路径作为期权定价预言机（oracle）——这是合成市场相对真实市场的关键优势：真值可知。在此之上，我们构建一个两阶段、动作条件的流匹配（Flow Matching, FM）世界模型（先方差、后收益），并提出两项贡献。第一，一种**严格恰当（strictly-proper）的路径分布微调**：它在一个可微的自由演化 rollout 上，用签名核 MMD、Sig- W_1 期望签名与能量分数（energy score）的组合，替代 Quant-GAN 的对抗式 WGAN-GP 判别器，把校准后定价误差从 0.583（基础 teacher）经 0.420（对抗判别器）单调改进到 **0.180**。第二，一项系统的少步蒸馏研究，并给出一个一致的机理解释：为什么“teacher + 一致性蒸馏”会在校准定价这一指标上超过 teacher 本身，而一致性之外的 Mean-Flow 与 flow-map 却在自由 rollout 下失败。贯穿训练与蒸馏的全部模型，我们提炼出一个稳健的 **raw ↔ 校准权衡**，并把任何低于预言机地板的校准数值识别并标注为校准假象（artifact）。我们公开全部代码与协议。

1 引言

1.1 我们到底要解决什么问题

金融机构需要“如果……会怎样”的能力：如果接下来进入一段崩盘行情，我的期权组合会如何？如果波动率持续抬升，做市策略的回撤有多大？历史数据里这类极端情景稀少且不可重放，于是人们转向生成式市场模拟器。但一个真正可用的模拟器必须满足三件事，缺一不可：

1. **可控（controllable）**。使用者要能指定情景——“给我一段崩盘”——而不是被动接受模型吐出的随机样本。这要求模型是动作条件的：一个外部智能体在每一步设定市场区制，模型据此响应。

2. **自洽 (self-consistent)**。模拟器要在自由演化下展开很长的时间跨度（我们用 一个交易年 = 252 步）而不崩坏。这远难于单步预测：单步的微小偏差会在 252 步上复合累积，把终端分布的尺度与尾部彻底带偏。
3. **金融保真 (financially faithful)**。生成路径上算出的衍生品价格要对。这与“边际直方图像不像”并不等价——一个模型可以把收益直方图拟合得很好却给期权定价错误，反之亦然 [8]。

1.2 为什么现有方法不够

把这三条放在一起，现有方法各有硬伤。**对抗式生成器**（以金融领域的标准基线 Quant-GAN [30] 为代表）训练不稳定，且其稳定化技巧常以压扁尾部为代价（其原始实现中的 LayerNorm+tanh 会把峰度压到接近正态）；GAN 也没有任何分布层面的保证。**经典计量经济模型**（GARCH [6] 及其重尾变体）能抓住波动率聚集，但它们不可控（没有区制这个动作维度），也无法作为可微的世界模型嵌入下游智能体。**非参数重采样**（块自助法）几乎完美地复刻边际分布——因为它就是在回放真实数据——但它结构上无法被驱动进入指定区制，也无法外推出数据中不存在的新情景。**逐步预测模型**（包括朴素训练的流匹配/扩散）只优化单步转移，从不优化它在自由 rollout 下实际产生的整条路径的分布，因而在长程复合下暴露偏差严重。

1.3 我们的思路与贡献

我们采取世界模型视角 [2, 14]。所谓世界模型，是指一个可学习的、动作条件的环境模拟器：它学习环境动态的转移核 $p_\theta(s_{t+1} | s_t, a_t)$ ，使得一个外部智能体可以反复“想象”地推演（rollout）未来，用于规划或评估，而无需与真实环境交互。一个对象要称为世界模型，需具备三要素——状态 s 、动作 a 、可自回归推演的学习转移核。本文的实例化是：**环境** = 市场的潜在状态 $s_t = (v_t, r_{t-1})$ （当前瞬时方差与上一期收益）；**动作** = 离散市场区制 $a_t \in \{\text{正常}, \text{高波动}, \text{崩盘}\}$ ，由使用者/智能体在每一步设定；**转移核** = 我们学习的两阶段条件分布 $p_\theta(v_t[t+1], r_t | v_t, r_{t-1}, a_t)$ (§3)。它满足全部三要素，并且可被动作驱动（指定区制即可生成对应情景）、可自由推演（自回归展开 252 步），因此是名副其实的世界模型，而不仅是一个收益分布拟合器。生成骨架选用流匹配 [1, 20, 21]——一个免模拟、训练稳定、且支持有原则少步蒸馏的连续时间框架。在此 teacher 之上：

贡献一（方法核心）：严格恰当的路径分布微调。 我们指出 teacher 的根本局限是“目标错配”：它最小化逐步回归损失，却从不直接约束它在自由 rollout 下产生的路径分布。我们因此在一个可微 rollout 上，用一组严格恰当 [11] 的路径分数（签名核 MMD [13, 17, 27]、Sig- W_1 [23, 24]、能量分数 [25]）替代 Quant-GAN 的对抗判别器。我们将论证：这些来自不同论文的思路之所以搬到我们这里恰好有效，是因为它们各自精确地命中了金融路径的一个互补侧面，而组合起来覆盖了“定价主导矩—时间结构—幅度结构”三个维度。

贡献二：少步蒸馏与“学生超越老师”的机理。 模拟器要便宜才实用。我们把多步 teacher 蒸馏为一步/少步学生（一致性 [28, 29]、Mean-Flow [9]、Lagrangian flow-map [5]）。我们不仅给出基准，

更给出一个一致的机理解释：一致性蒸馏在长程复合 rollout 中扮演了”端点投影/方差缩减”的角色，因而能在校准定价上超过 *teacher*；而同一机制压扁尾部，于是它只在这一个轴上超越——这与全文权衡完全自洽。

贡献三：诚实的评测与校准假象。 我们以自由 rollout 在留出测试集与独立 MC 预言机上评测，并同时报告 RAW（未校准）与 CAL（矩校准）。真实测试集自身相对预言机的定价误差为 0.165（有限样本地板）。我们表明单次仿射矩校准即可把误差压到地板以下，并论证这是注入两个数据统计量的假象而非生成质量——这一区分在金融生成文献中被普遍低估。

我们的核心结论：基础 FM teacher 是 RAW 自洽冠军（0.475）；调度采样给出最佳程式化事实平衡（峰度 4.41 vs. 真实 4.60）；我们的严格恰当微调给出最佳诚实校准定价（0.180）；而 raw 自洽与校准定价之间存在一条无法被事后手段抹去的系统张力。

2 相关工作

金融时间序列生成。 Quant-GAN [30] 用时序卷积生成器 + Lambert-W 重尾输出 [12] + WGAN-GP 训练。Sig-WGAN 及其条件变体 [23, 24] 用基于签名的 Wasserstein-1 距离替换判别器，利用签名 [22] 线性化路径泛函的性质。TimeGAN [31] 在学习嵌入中结合对抗与监督损失。经典基线 GARCH/GJR [6, 7, 10] 在波动率聚集上仍是必须超越的参照。

流匹配、扩散与世界模型。 流匹配 [20]、修正流 [21] 与随机插值 [1] 学习把噪声输运到数据的连续时间速度场，规避了扩散 [16, 18] 在采样上的困难。世界模型 [2, 14] 学环境的动作条件模拟器；本文把这一视角引入量化金融。

严格恰当评分规则。 若评分规则的期望仅在真实分布处唯一最小化，则称严格恰当 [11]。能量分数与核/MMD 分数 [13] 均严格恰当，已被用于训练概率预测器 [25] 与无判别器神经 SDE [17]。

少步蒸馏。 一致性模型 [28, 29] 学沿概率流 ODE 不变的一步映射；Mean-Flow [9] 学时间平均速度；flow-map 自蒸馏 [5] 学双时映射 $X(x, s, t)$ ，可用 K 步复合换质量。本文首次在自由演化金融 rollout 下统一比较三者。

3 问题动机与数据合成

3.1 数据如何合成，以及为什么这样设计

我们需要一个既现实又真值可知的测试平台。现实性来自 Heston 随机波动率模型 [15]：它内生地产生波动率聚集与（通过 $\rho < 0$ 的杠杆相关）负偏。但单一 Heston 过于平稳、过于简单。我们因此叠加一个三区制马尔可夫切换，使数据具备三种现实特征：重尾（来自三区混合）、非平稳

(区制随机切换)、以及一个天然的可控动作 (区制本身)。在区制 $a \in \{\text{正常, 高波动, 崩盘}\}$ 下,

$$dS_t = \mu_a S_t dt + \sqrt{v_t} S_t dW_t^S, \quad (1)$$

$$dv_t = \kappa_a(\theta_a - v_t) dt + \xi_a \sqrt{v_t} dW_t^v, \quad d\langle W^S, W^v \rangle_t = \rho_a dt. \quad (2)$$

三个区制的参数 $(\kappa, \theta, \xi, \rho, \mu)$ 分别为 $(2, 0.04, 0.3, -0.7, 0.05)$ 、 $(3, 0.09, 0.5, -0.7, 0.05)$ 、 $(4, 0.16, 0.8, -0.7, -0.2)$: 正常区制温和上行; 高波动区制把长期方差 θ 与波动率之波动 ξ 同时抬高; 崩盘区制兼具最高的 θ, ξ 与负漂移 $\mu = -0.2$, 从而制造肥厚的左尾——这正是风险管理最关心、历史数据最稀缺的情景。区制按行随机转移矩阵演化, 对角线高度持久 $(0.992, 0.95, 0.90)$, 使每个区制成片出现而非逐日抖动, 符合真实市场”平静期—危机期”交替的特征。

离散化与切分。 我们以 $dt=1/252$ 、 $T=252$ 步、 $S_0=100$ 、 $v_0=0.04$ 模拟。为避免欧拉格式的方差截断偏差, 方差用 Andersen [3] 的二次一指数 (QE) 格式离散, 对数收益用其带鞅修正的更新式——这是文献中精度最高的 Heston 离散方案之一, 保证我们的”真值”本身可靠。我们生成训练 50k、验证 5k、测试 10k 条路径 (种子 20260530), 并独立地 (种子 20260519) 再生成 100k 条作为 MC 预言机。

为什么用合成数据。 关键不在”省钱”, 而在真值可知。因为我们掌握真实的数据生成过程, 就能在 100k 条独立真路径上用蒙特卡洛算出无偏的期权价格作为定价参照——这是真实市场永远做不到的 (真实市场没有”正确价格”标签)。这把”生成器好不好”从主观的视觉判断变成了可证伪的数值问题。

3.2 世界模型分解

我们自回归地建模单步转移。记 r_t 为对数收益、 a_t 为区制动作, 世界模型把每步分解为

$$p_\theta(v_t[t+1], r_t | v_t, r_{t-1}, a_t) = \underbrace{p_\theta^{\text{vol}}(v_t[t+1] | v_t, r_{t-1}, a_t)}_{\text{方差阶段}} \underbrace{p_\theta^{\text{ret}}(r_t | v_t[t+1], v_t, r_{t-1}, a_t)}_{\text{收益阶段}}, \quad (3)$$

其中 $r_{-1}=0$ 。先采方差、再采 (以新方差为条件的) 收益, 这一因果顺序与 Heston 的结构一致。完整模拟通过自由演化 rollout 产生: 采 $v_t[t+1]$, 再采 r_t , 追加, 在外部选定的区制序列下重复 252 步。

3.3 评测协议 (生成式、留出式、无教师强制)

我们强调评测的”诚实性”, 因为很多金融生成工作只报单步或教师强制指标, 而那会系统性高估自由生成能力。我们的协议是: 模型只在训练集上训练、用验证集选检查点; 评测时让模型从零自由生成 5000 条全新路径 (从 S_0, v_0 出发、区制由马尔可夫链采样、FM ODE 用 16 步积分、全程不看测试集), 再做三类比较:

- **相对 MC 预言机的期权定价 RMSE** (首要金融指标): 欧式看涨, 价值度 $\{0.85, 0.90, 0.95, 1.00, 1.05\} \times$ 到期 $\{0.25, 0.5, 1.0\}$ 。真实测试集相对预言机的误差为 **0.165**——有限样本地板, 任何生成器都不该”诚实地”低于它。
- **程式化事实**: 主看池化对数收益的峰度 (真实 **4.60**), 辅以收益/绝对收益自相关、杠杆相关。
- **签名-Wasserstein 距离** (深度 3): 度量整条路径分布的差异。

raw 与 **cal**, 以及地板的意义。RAW 直接用生成器输出。CAL 施加单次仿射矩校准: 把池化生成收益标准化后, 重缩放到训练数据的收益均值与标准差 (故无测试泄漏), 再定价。校准对只需价格的从业者合理, 但它恰好注入两个主导期权价格的数 (前两阶矩)。因此任何低于 0.165 的 **cal** 都是校准假象, 我们一律标注。

4 方法

4.1 两阶段流匹配世界模型, 以及为什么是 FM 而非扩散或 GAN

流匹配 [20] 学一个速度场 $v_\theta(x, \tau, c)$, 把 $\tau=0$ 的高斯先验沿直线插值 $x_\tau = (1 - \tau)x_0 + \tau x_1$ 输运到 $\tau=1$ 的数据, 目标为

$$\mathcal{L}_{\text{FM}} = \mathbb{E}_{\tau \sim U[0,1], x_1 \sim \mathcal{D}, x_0} \|v_\theta(x_\tau, \tau, c) - (x_1 - x_0)\|^2. \quad (4)$$

方差阶段 x_1 为 (归一化对数) 下一方差、 $c = (v_t, r_{t-1}, a_t)$; 收益阶段 x_1 为下一对数收益、 $c = (v_t[t+1], v_t, r_{t-1}, a_t)$ 。速度场是残差 MLP (隐藏 256、6 块、正弦时间嵌入), 批 4096、60 轮、余弦学习率 2×10^{-4} 、10% 动作 dropout (以便区制的无分类器引导)。

为什么 FM 的思路在这里特别有效。 本任务的单步条件分布是一维、连续、单峰的 (给定状态与区制, 下一收益/方差的分布形状温和)。这恰是 FM 的甜区: (i) 它免对抗, 不会像 GAN 那样模式崩塌或压扁尾部——这正是 Quant-GAN 的痛点; (ii) 它学的是直线输运, ODE 近似仿射, 少步积分误差小——这在我们把单步采样复合 252 次的场景里至关重要: 每步的积分误差会沿 rollout 累积, 越直的轨迹累积越少。我们在实验中用一个同架构、同两阶段的 DDPM 基线验证了这一点: 把目标换成扩散去噪、采样换成扩散采样后, RAW 自洽性从 FM 的 0.475 急剧恶化到 2.855 (§5)。这不是实现差异, 而是”直线输运 vs 弯曲扩散轨迹”在长程复合下的本质差别。

调度采样 (scheduled sampling, SS): 直击暴露偏差。 暴露偏差 (exposure bias) 指: teacher 训练时, 条件 r_{t-1} 永远是真实的上一期收益 (教师强制); 但自由部署时, 条件变成模型自己上一步生成的收益。二者分布不同, 模型在训练中从未”见过”自己的输出分布, 于是一旦自由 rollout, 误差会在 252 步上复合放大——这就是长程暴露偏差。调度采样 [4] 的做法是: 训练时以概率 p 把条件 r_{t-1} 换成模型自身的采样值 (而非真值), 让模型在训练阶段就暴露于自己的误差分布。我们取 $p=0.8$, 得到最佳程式化事实平衡 (峰度 4.41, 最接近真实 4.60): 它不直接降低定价误差, 但显著改善长程形状稳定性, 是 RAW 与形状之间最甜的折中。

Lambert-W 重尾核 (LWFM)——一个探索性变体，非最优流程的一部分。为诚实起见我们明确说明：我们探索过在流匹配前对收益施加 Lambert-W 重尾变换 [12] (参数 δ)、采样时反演以重注尾部，记为 LWFM。一个小扫描 ($\delta \in \{0.03, \dots, 0.12\}$) 确实把峰度从 3.88 推到 4.3 附近、更接近真实 4.60 (§5)。但它并未进入我们最终最优的流程：最佳校准定价 (0.180) 来自把路径损失微调施加在大批量配方 *teacher* (不含 LWFM) 之上。因此本文把 LWFM 报告为”有益但非必要”的尾部建模变体，而非核心组件——这也提醒：单点改善峰度 (LWFM) 与改善定价 (路径损失) 针对的是不同维度。

4.2 严格恰当的路径分布微调 (本文方法)

痛点。 *teacher* 最小化的是逐步回归损失：它学”给定真实的上一时刻，下一时刻像不像”。但它从不优化它在自由 *rollout* 下产生的整条路径的分布——而后者才是我们真正部署、真正评测的对象。这个”训练目标”与”部署目标”之间的缺口，是长程暴露偏差的根源。

思路：用可微 rollout + 严格恰当路径分数闭合缺口。 我们把 FM 采样器重参数化，使梯度能穿过 252 步生成，得到生成路径批 $\hat{R} \in \mathbb{R}^{B \times T}$ ，并用一组严格恰当 [11] 路径分数与真实批 R 比较，替代 Quant-GAN 的 WGAN-GP 判别器：

$$\mathcal{L} = \lambda_{\text{sig}} \mathcal{L}_{\text{sigMMD}} + \lambda_{w_1} \mathcal{L}_{\text{SigW}_1} + \lambda_e \mathcal{L}_{\text{energy}} + \mathcal{L}_{\text{moment}}, \quad (5)$$

其中 $\mathcal{L}_{\text{moment}}$ 聚合低阶矩、终端方差、绝对收益、峰度匹配，及一个使微调后场不偏离 *teacher* 太远的锚定正则。

为什么”别人论文的思路”搬到这里恰好有效——它们各自命中一个互补侧面。这是本节的关键论证。金融路径的真实性不是单一标量，而是若干不同性质的统计量的并集；我们选的三个分数恰好覆盖了互补的三块，且都严格恰当（即不会像对抗判别器那样给出无意义的最优）：

- **签名核 MMD (命中”时间/序列结构”)**。签名 [22] 把一条路径映成它所有迭代积分的张量，线性化了路径泛函——而我们关心的程式化事实（已实现方差、波动率聚集）与期权收益本身就是路径泛函。于是在签名特征上做 MMD [13, 17, 27]，等价于直接比较”我们真正在意的那些路径量”的分布：

$$\mathcal{L}_{\text{sigMMD}} = \mathbb{E} k(\phi_R, \phi_{R'}) + \mathbb{E} k(\phi_{\hat{R}}, \phi_{\hat{R}'}) - 2 \mathbb{E} k(\phi_R, \phi_{\hat{R}}), \quad \phi = \mathbf{S}(\cdot) \text{ 深度3}. \quad (6)$$

- **Sig-W₁ 期望签名 (命中”一阶路径泛函的均值”)**。 $\mathcal{L}_{\text{SigW}_1} = \|\mathbb{E}[\mathbf{S}(R)] - \mathbb{E}[\mathbf{S}(\hat{R})]\|$ [23, 24] 匹配截断深度内所有多项式路径泛函的期望，给签名 MMD 提供一个低方差、强信号的一阶约束。
- **能量分数 (命中”幅度/联合尺度”)**。 $\mathcal{L}_{\text{energy}} = 2\mathbb{E}\|R - \hat{R}\| - \mathbb{E}\|\hat{R} - \hat{R}'\| - \mathbb{E}\|R - R'\|$ [25] 是标准化收益路径上的总体能量距离，对整体幅度与联合尺度敏感——这正是签名类分数容易忽视的维度。

为什么必须组合，且组合严格优于任一单项。这不是”把几个 loss 堆在一起”，而是有可证伪的机理。每个分数都只对它所”覆盖”的统计量子空间严格恰当，对其余子空间不敏感，因而单用时会沿不敏感方向自由漂移：实验中 (§5.3) 仅签名类分数对齐了路径形状但对绝对尺度无约束，于是尺度漂移、校准崩坏 ($CAL > 10$)；仅能量/仅矩锁住了尺度却放任时间结构。把三者相加，等价于把它们各自的”零损失流形”求交集：唯有同时对齐时间结构（签名）、一阶路径泛函均值 (Sig- W_1)、幅度尺度（能量）与定价主导矩（矩项）的分布，总损失才接近零——这就是组合严格优于单项的数学原因。我们的原创性不在于发明这些分数，而在于三点此前未被组合实现的设计：(i) 首次把一组严格恰当的路径分数组织进一个可微世界模型的自由 *rollout* 微调中，从而直接对”部署时真正产生的路径分布”求梯度，闭合了逐步训练与自由部署之间的目标缺口；(ii) 论证并实验证明这三个分数在金融路径上恰好张成互补且必要的三维，给出一个可复用的”路径真实性 = 时间结构 $\oplus$ 一阶泛函 $\oplus$ 幅度尺度 $\oplus$ 定价矩”的设计范式；(iii) 以此替换 Quant-GAN 的对抗判别器——我们放弃判别器的自适应，换来训练稳定性、无 min-max 振荡、以及随权重单调可改进 ($CAL: 0.583 \rightarrow 0.420 \rightarrow 0.362 \rightarrow 0.180$) 这一可控行为。

我们冻结方差阶段，对收益阶段以学习率 5×10^{-6} 微调 10 轮（批 512、rollout ODE 4 步）， $(\lambda_{\text{sig}}, \lambda_{w_1}, \lambda_e) = (200, 5, 10)$ 。

4.3 少步蒸馏，以及”学生为何能超越老师”

在 252 步 rollout 上每步每阶段做 16 步 ODE 代价高昂。我们把 teacher 蒸馏为一步/少步学生：一致性蒸馏(CD) [28, 29] 学一个其一步输出沿 teacher ODE 不变的学生；Mean-Flow(MF) [9] 学时间平均速度以一步采样；Lagrangian flow-map [5] 学双时映射 $X(x, s, t) = x - (t-s)G_\theta(x, s, t)$ ，沿映射自身轨迹强制 $\frac{d}{dt}X = v_{\text{teacher}}(X, t)$ ，并支持 K 步复合。

为什么”teacher + 一致性”能在校准定价上超过 teacher 本身——一个方差缩减/端点投影的解释。这看似反直觉（学生不该比老师强），但在我们的长程复合 *rollout* 设定下有清晰机理。teacher 的每一步都用一个多步随机 ODE 采样器（16 步）从噪声积分到样本；每次积分都注入新的采样噪声与离散化误差，这些误差沿 252 步以近似随机游走的方式累积，污染终端收益分布的尺度（方差）结构。一致性学生把 teacher 的整条 ODE 轨迹压缩成一个确定性的一步映射（把 z 直接送到 ODE 端点），这在效果上等价于对 teacher 采样器做了一次端点投影/方差缩减：单步映射不再逐步注入积分噪声，于是复合 rollout 的累积误差更小，终端方差结构更干净、更稳定。而期权价格——尤其校准后定价——几乎完全由终端方差主导，因此”更干净的终端方差”直接转化为更低的 CAL：这就是 combined-CD 把 CAL 从 teacher 的 0.232 降到 0.170、C3-CD 从 0.283 降到 0.118 的来源。但这不是免费的：同一个”压缩/平滑”操作也削平了重尾——学生峰度从 teacher 的 ~ 3.6 掉到 3.1/2.85。于是学生只在 CAL 这一个轴上超过 teacher，而在 RAW 自洽与峰度上变差。数据中”CAL 降、峰度同向降”的指纹，正是这一机制的证据，也与全文 $\text{raw} \leftrightarrow$ 校准权衡完全自洽：蒸馏不是凭空变强，而是把”采样噪声/尾部真实性”换成了”终端方差的洁净度”。此外，FM 的直线插值使 teacher ODE 近似仿射、曲率低，一步一致性映射易学；这也是 CD（而非 MF/flow-map）能成功迁移的结构性原因——后两者要逼近的”平均速度/双时映射”在重尾、强状态依赖、且需复

表 1: 各模型/家族的关键训练配置 (FM/扩散均为同一两阶段残差-MLP 架构)。SS= 调度采样比例；动作 dropout 用于无分类器引导；路径损失微调冻结方差阶段、仅微调收益阶段。

模型 / 家族	架构 (隐藏 $\times$ 块)	批大小	轮数/步数	学习率	关键设置
FM 世界模型 (基础 teacher)	256 $\times$ 6	4096	60 轮	2e-4 余弦	动作 dropout 0.1; 无
+ 调度采样 (SS)	收益 128 $\times$ 4	512	15 轮	3e-4	SS= 0.8 (沿用基础方差)
大批量配方 teacher	256 $\times$ 6	8192	方差 20/收益 15 轮	1e-3/5e-4	SS= 0.5 (路径损失微调)
路径损失微调 (本文方法)	冻结方差/微调收益	512	10 轮 (rollout 4 步)	5e-6	$\lambda_{\text{sig},w1,e}=(200, 5, 10)$ +
DDPM (同架构, 扩散基线)	256 $\times$ 6	4096	30k 步	2e-4 余弦	$T=1000$; 50 步采样
一致性蒸馏 (CD 学生)	同 teacher 架构	512	15 轮	3e-4	1 步采样 (NFE= 1)

合 252 次的条件下是远更难的回归目标，微小偏差以乘性方式放大，导致尾部发散 (§5.4)。

5 实验与结果

实现与基线。 模型在 RTX-5090 上以 PyTorch 训练。基线含：(i) **Quant-GAN** [30] 原版配方 (best/last)；(ii) **GARCH(1,1)-t** [6, 7] (MLE 拟合, $\hat{\alpha}=0.082, \hat{\beta}=0.911, \hat{\nu}=6.1$, CPU)；(iii) **DDPM**: 与 FM teacher 同架构、同两阶段、同 *rollout*、同评测，仅把目标换成扩散去噪、采样换成 50 步扩散采样——专门用来回答“为什么选 FM 而非扩散”；(iv) **块自助法** [19, 26] (块长 21) 作为非生成参照 (数据回放，见表注)。所有 FM/扩散模型共享同一两阶段架构与同一评测，仅训练目标/配置不同；关键配置见表 1，便于复现并厘清各模型差异。

5.1 主结果

表 2 给出头部对比。其一，**基础 FM teacher** 在学习型生成器中取得最佳 RAW (**0.475**)，逼近地板，远胜同架构的 **DDPM** (2.855)、**GARCH-t** (1.089) 与 **Quant-GAN** (5.4-5.7)；其近乎相等的 RAW/CAL (0.475/0.583) 说明它真正自洽、不靠校准。DDPM 与 FM 的鸿沟 (2.855 vs 0.475) 直接印证了 §4.1 的论断：在长程复合下，直线输运的累积误差远小于弯曲扩散轨迹。其二，**调度采样** (FM+SS) 给出最佳程式化事实平衡 (峰度 4.41、CAL 0.348)，是 RAW 与形状之间最甜的内点。其三，我们的**严格恰当微调**给出最佳诚实校准定价 (**0.180**)，优于对抗判别器 (见表 4)。作为对照，**GARCH-t** 的 RAW 出人意料地好 (1.089，因为它把无条件方差拟合得准)，但峰度爆炸到 19.2 且不可控——再次说明“好定价”与“好路径真实性”是两个轴；**块自助法** (数据回放) 几乎贴着地板，但那是参照天花板而非竞争者 (它不可控、不可外推)。

逐模型优势与劣势分析。 主推三模型各自的优势与适用场景：(a) *FM 基础 teacher* 的优势是真正自洽——RAW/CAL 几乎相等 (0.475/0.583) 说明它不靠校准就能正确定价，适合作为下游智能体反复推演的无偏模拟器；其短板是峰度偏低 (3.88)，尾部略不足。(b) *FM+* 调度采样的优势是形状最真 (峰度 4.41 最接近 4.60) 且 CAL 不错 (0.348)，适合关注程式化事实/风险形状的场景；

表 2: 三区制 Heston 任务在自由演化 rollout 下的主对比 (训练配置见表 1)。RAW/CAL = 未校准/矩校准的相对 MC 预言机期权定价 RMSE (越低越好; 有限样本地板 0.165)。峰度目标 4.60。Quant-GAN 为我们依原论文复现的实现。”大批量配方 teacher”指更大批量 (8192)+ 调度采样 (0.5) 训练的同架构 teacher, 是路径损失微调的基座。”加重矩/锚定”指在路径损失上调高矩匹配与锚定正则的权重; ”延长训练”指微调 15 轮。蒸馏行” $X \leftarrow Y$ ”表示用方法 X 蒸馏 teacher Y 。[†]CAL 低于地板: 校准假象。[‡]非生成参照 (数据回放): 复用真实收益, 故逼近地板在意料之中, 但不可控、不可外推, 是参照而非竞争生成器; ”真实测试集”行即定价地板本身。* 学习型生成器中最佳。各列学习型最佳以**粗体**。

	模型	RAW ↓	CAL ↓	峰度 (→ 4.60)
参照 (非生成)	真实测试集 (vs 预言机)	0.165	—	4.60
	块自助法 [‡] (数据回放) [26]	0.269	0.244	4.58
基线	Quant-GAN (论文复现, best) [30]	5.650	1.607	10.21
	Quant-GAN (论文复现, last) [30]	5.429	0.674	6.39
	GARCH(1,1)- t [6]	1.089	0.482	19.17
	DDPM (与 FM 同架构/两阶段, 扩散目标) [16]	2.855	0.576	3.75
Teacher	FM 世界模型 (基础, 256×6)	0.475*	0.583	3.88
	+ 调度采样 SS ($p=0.8$, 缓解暴露偏差)	0.872	0.348	4.41
	+ LWFM 重尾核 ($\delta=0.05$, 探索性变体)	0.882	—	4.33
	大批量配方 teacher (bs 8192+SS0.5, 微调基座)	1.057	0.582	4.08
路径损失微调 (本文方法, 基于大批量 teacher)	基础权重	2.595	0.232	3.66
	加重矩/锚定权重 (最佳 cal)	2.595	0.180	3.63
	延长训练 15 轮	1.483	0.283	3.68
一致性蒸馏 (CD, 1 步)	CD $\leftarrow$ FM+SS teacher (平衡学生)	1.282	0.371	4.27
	CD $\leftarrow$ 路径损失 teacher (cal 0.232)	1.875	0.170 [†]	3.11
	CD $\leftarrow$ 路径损失 teacher (低 lr, 最强 cal)	2.328	0.118 [†]	2.85

代价是 RAW 略升到 0.872。(c) 路径损失微调 (加重矩/锚定) 的优势是校准定价最优 (0.180), 适合接入市场报价后的精确定价; 其短板是 RAW 升到 2.595、峰度降到 3.63——它把能力集中投到了”定价主导矩”上。**表现差的模型, 劣势与成因:** *Quant-GAN* (RAW 5.4-5.7) 成因是对抗训练不稳定 + 其稳定化技巧压扁/扭曲尾部 (峰度高达 10.2), 且无区制条件; *DDPM* (RAW 2.855) 与 FM 同架构却差 6 倍, 成因是扩散的弯曲采样轨迹在 252 步复合下累积误差远大于 FM 的直线输运 (这是选 FM 的直接证据); *GARCH-t* 峰度 19.2 的成因是它把整段时间的条件方差混合成一个无条件重尾分布, 缺少区制结构去组织尾部。

5.2 超越 RMSE: 多维度的真实性

仅看定价 RMSE 会掩盖一个事实: 路径真实性是多维的。表 3 报告四类互补指标——签名-Wasserstein (整条路径分布)、绝对收益自相关 L1 (波动率聚集)、杠杆相关 L1 (杠杆效应)、尾指数与峰度 (尾部厚度)。结论是**没有单一赢家**, 这恰是全文 raw $\leftrightarrow$ 校准权衡在更多维度上的体现。

表 3: 关键模型的扩展指标（自由 rollout，对真实测试集）。签名-W、绝对收益 ACF-L1（波动率聚集）、杠杆 ACF-L1 越低越好；尾指数目标 ≈ 4.28 、峰度目标 4.60。”真实测试集/块自助法”为非生成参照（灰义）。各列在生成型学习模型中的最优以粗体。

模型	签名-W ↓ ($\times 10^{-2}$)	波动聚集 ↓ (absACF-L1)	杠杆 ↓ (lev-L1)	尾指数 $\rightarrow 4.28$	峰度 $\rightarrow 4.60$
真实测试集（参照）	0.00	0.000	0.000	4.28	4.60
块自助法（数据回放）	0.59	0.0354	0.0040	4.30	4.58
Quant-GAN（复现，last）	2.03	0.0050	0.0035	4.03	6.39
GARCH(1,1)-t	0.85	0.0104	0.0291	2.82	19.17
DDPM（同架构）	1.66	0.0223	0.0085	4.85	3.75
FM 世界模型（基础）	1.20	0.0156	0.0052	4.78	3.88
FM + 调度采样	1.04	0.0111	0.0063	4.39	4.41
大批量配方 teacher	0.99	0.0148	0.0103	4.61	4.08
路径损失（最佳 cal）	4.48	0.0308	0.0143	5.49	3.63
CD $\leftarrow$ FM+SS（平衡学生）	0.84	0.0018	0.0037	4.47	4.27
CD $\leftarrow$ 路径损失	5.76	0.0285	0.0078	6.99	3.11

从扩展指标读出的故事。（1）路径级真实性的赢家是”调度采样及其一致性学生”：CD $\leftarrow$ FM+SS 在签名距离、波动率聚集、杠杆三项上同时最优（波动聚集 0.0018，比 FM 的 0.0156 好近一个数量级），FM+ 调度采样则在尾指数/峰度上最接近真实。这说明”治暴露偏差 (SS) + 端点投影 (CD)”对动态结构的恢复最有效。（2）块自助法的破绽被这张表抓住：它签名距离极低（0.0059，因为就是真实数据），但波动率聚集是所有正经模型里最差（0.0354，甚至差于 GARCH 的 0.0104）——因为 21 天分块拼接破坏了跨块的长程波动率聚集。它”回放边际”却”打断动态”，再次印证它是参照而非可用生成器。（3）我们最佳 cal 模型（路径损失/CD $\leftarrow$ 路径损失）的代价在此可见：它们签名距离与波动率聚集明显变差（签名-W 0.045-0.058），尾部甚至过厚（尾指数 5.5-7.0）——这正是它们 RAW 差的根因：为压低校准定价的两个主导矩，牺牲了路径级动态。（4）GARCH 与 DDPM 的劣势成因：GARCH 杠杆相关最差（0.0291，它没有杠杆机制）且尾指数 2.82 过厚（峰度 19）；DDPM 各项平庸且签名距离差于 FM，印证扩散弯曲轨迹在长程复合下的劣势。

5.3 消融：单个恰当分数为何不足、组合为何成功

表 4 在同一 teacher/rollout 上隔离各组件，直接验证 §4.2 的互补性论证。仅签名类分数 (sig-MMD / Sig-W₁) 因无视绝对尺度而把校准搞崩 (CAL 15.1/11.8) ——它们对齐了路径形状却放任幅度漂移，而幅度直接决定期权价格。仅能量或仅矩抓住了尺度却丢了时间结构，停在 CAL 1.5-2.9。对抗式 WGAN-GP 判别器（把 Quant-GAN 目标移植到我们的 rollout）达 CAL 0.420。只有组合的严格恰当一篮子达到 CAL 0.362：因为它同时锁住”时间结构（签名）+ 幅度（能量）+ 定价主导矩（矩项）”。这条消融正是组合严格优于单项的直接证据——任一单项都不行，合起来既稳又全。两点澄清。其一，此处的 WGAN-GP 行不是我们方法的一部分：它是把 Quant-GAN 的对

表 4: 路径分布损失的组件消融（同一 teacher/rollout）。任一单项均不足；组合击败对抗式 WGAN-GP 判别器。

路径损失配置	RAW ↓	CAL ↓	峰度 (→ 4.60)
仅矩 (控制组)	2.566	2.904	3.49
仅 sig-MMD	5.510	15.08	4.78
仅 Sig- W_1	4.971	11.79	4.59
仅能量	1.814	1.555	3.39
WGAN-GP 判别器 (Quant-GAN 目标)	1.746	0.420	4.21
组合 (sig-MMD + Sig- W_1 + 能量 + 矩)	1.717	0.362	4.22

表 5: 一步蒸馏。一致性蒸馏 (CD) 迁移成功并在 CAL 上超过其 teacher；Mean-Flow (MF) 失败。[†] 低于地板的 CAL：校准假象。

Teacher	学生	RAW ↓	CAL ↓	峰度 (→ 4.60)
FM 基础	CD	4.810	0.537	4.48
FM 基础	MF (失败)	9.084	1.442	3.52
FM + SS (B1)	CD	1.282	0.371	4.27
FM + SS (B1)	CD (低学习率)	1.005	0.444	4.27
路径损失 (cal 0.232)	CD	1.875	0.170 [†]	3.11
路径损失 (cal 0.283, 长训)	CD (低学习率)	2.328	0.118 [†]	2.85
路径损失	MF (失败)	7.536	37.62	2.49

抗判别器目标移植到相同可微 rollout 上，作为”对抗 vs 严格恰当”的对照——我们的方法用严格恰当分数替换了它 (CAL 0.362 < 0.420)，并且没有 min-max 振荡。其二，本表组合的 CAL 0.362 与表 2 的最佳 0.180 是同一方法在不同 teacher 基座上的结果：本消融为公平起见统一在 LWFM teacher 上做单变量对照，而表 2 的最优来自把同一路径损失施加在大批量配方 teacher 上并加重矩/锚定权重——可见基座与权重共同决定终值，但”组合 > 单项 > 对抗”的结论与基座无关。

5.4 蒸馏研究：一致性迁移、Mean-Flow 失败

表 5 印证 §4.3 的机理。**一致性蒸馏**跨 teacher 迁移成功：它既保住平衡学生的形状 (B1→CD 峰度 4.27、RAW 1.28)，又继承本文方法的校准优势，并通过”端点投影/方差缩减”把 CAL 进一步压到 0.170——超过其 teacher 的 0.232。最强校准 (C3-CD 0.118) 与最低 RAW (B1-CD 低学习率 1.005) 也都来自蒸馏。与此对照，**Mean-Flow 失败**：无论何种 teacher，MF 学生都退化 (FM→MF RAW 9.08) 或爆炸 (本文方法 →MF CAL 37.6、峰度坍到 2.49)。机理如 §4.3：MF 的”时间平均速度”对重尾、强状态依赖、且需复合 252 次的收益条件分布是糟糕的拟合，单步偏差以乘性累积。**重要的诚实警示**：最强校准 (CAL 0.118-0.170) 虽亮眼，但低于地板者带校准假象，且 RAW/峰度差——它们是定价加速器而非更好的生成器。

表 6: 少步 Lagrangian flow-map 学生的 NFE (K) 扫描 (单一检查点)。拐点依指标而异 (RAW: $K=2$; CAL: $K=1$); 更多步数膨胀尾部。

K (NFE)	1	2	4	8
RAW ↓	2.736	1.819	3.090	3.437
CAL ↓	0.313	2.355	3.745	3.857
峰度 ($\rightarrow 4.60$)	4.86	5.53	7.85	8.10

5.5 少步 flow-map: NFE 拐点依指标而异

表 6 在 $K \in \{1, 2, 4, 8\}$ 上扫描 Lagrangian flow-map 学生。最优 NFE 随指标变化: RAW 在 $K=2$ 最佳 (1.82), CAL 在 $K=1$ 最佳 (0.313)。增加步数并不单调有益——峰度从 4.86 ($K=1$) 膨胀到 8.10 ($K=8$), 因为复合放大尾部误差。flow-map 在极低 NFE 下有竞争力但不及一致性蒸馏; 一次热启动符号审计也未能修复, 说明其弱点是 rollout/路径分布错配而非初始化。

6 对比分析与讨论

一条贯穿全文的主线: raw↔ 校准权衡。把表 2-5 串起来看, 存在一条几乎无例外的规律: 每一个降低校准定价或把峰度推向目标的操作, 都以 RAW 自洽为代价, 反之亦然。基础 FM teacher 处一端 (RAW 0.475、CAL 近乎相等、真正自洽); 我们的路径损失与 CD 学生处另一端 (CAL 低至 0.118 但 RAW > 2 、峰度 < 3); 调度采样是最甜的内点。这条主线把全文的看似零散的现象统一了起来: 优化”两个主导定价的矩”(校准、终端方差为主的损失、一致性蒸馏的方差缩减都在做这件事) 必然牺牲”路径级真实性(尤其尾部)”。我们的方法不是要打破这条权衡(事后手段做不到), 而是沿着它给出三个有价值的工作点: raw 冠军 (teacher)、平衡冠军 (调度采样)、校准冠军 (路径损失 / CD)。

校准假象: 为什么不能只报一个校准数。期权价格由终端方差主导, 故钉住前两阶矩即可把 CAL 压到地板以下。我们最激进的一致性学生 CAL 0.118、却 RAW 2.33、峰度仅 2.85。它不是更好的生成器——是注入两个数据统计量的假象, 其糟糕的 RAW/峰度即是明证。因此我们主张: RAW 与 CAL 必须并报, 任何低于地板的 CAL 仅作诊断。这对金融生成文献是一个方法论提醒——单一校准定价数极易误导。

为什么”借来的思路”在这里成立——一个统一视角。本文用到的外部思路 (FM、签名/能量恰当分数、一致性蒸馏) 之所以在我们的设定下有效, 根因是同一个: ”我们的任务是低维、连续、需复合很多步的条件生成。”低维连续使 FM 的直线输运稳定、易蒸馏; ”需复合很多步”使”直线 vs 弯曲””逐点匹配 vs 平均匹配””注入噪声 vs 端点投影”这些原本在单步看不出差别的选择, 被放大成显著的累积差异——于是 FM $>$ DDPM、CD $>$ MF/flow-map、CD 甚至 $>$ teacher (在 cal 上)。签名/能量则因为”金融真实性就是一组路径泛函”而天然契合。换言之, 是任务结构 (复合 + 路

径泛函)决定了这些思路的成败,这也是本文最可迁移的洞见。

校准在真实市场怎么做,以及合成研究为什么有意义。 读者会问:CAL用了”真实数据的前两阶段”,真实市场上做得到吗?做得到,而且这正是业界实践。在真实市场,校准不是去对齐”未来真值”(那不可知),而是对齐当下可观测的市场信息:用历史窗口估计收益均值/方差,或更标准地,把模型的隐含波动率校准到当前期权市场报价(implied-vol surface)。我们合成实验里的”矩校准”正是这一真实流程的最小化代理。因此RAW/CAL的区分在真实市场原样成立:RAW衡量模型无条件的内在生成质量,CAL衡量接入市场报价后的实用定价能力——二者都重要,但不能用后者冒充前者。那么在”真值可知”的合成市场上做研究意义何在?意义恰恰在于:真实市场没有正确价格标签,无法判定一个生成器到底好在哪、坏在哪;而合成市场让我们用MC预言机得到无偏真值,从而干净地隔离并证明几条本身与合成无关的机理——直线输运在长程复合下优于扩散(FM>DDPM)、一致性蒸馏的端点投影/方差缩减、严格恰当分数的互补性、以及校准假象的存在性。这些结论是关于算法与任务结构的,不依赖数据是否合成,因此可迁移到真实数据;合成只是提供了一个能证伪它们的实验台。这也是本文主张的方法论贡献:先在可控环境证清楚机理,再迁移。

局限。 本文方法改进校准定价但不改进raw自洽;事后微调无法二者兼得。我们推测应把恰当评分的路径损失纳入teacher原生训练目标与检查点选择,而非事后施加。我们也只研究合成市场,向真实微观结构数据的迁移仍是开放问题。

7 结论与展望

我们提出了一个面向区制切换金融市场的、动作条件、两阶段流匹配世界模型,并在其上给出两项贡献:一种严格恰当的路径分布微调(替代Quant-GAN对抗判别器,给出最佳诚实校准定价0.180),以及一项系统的蒸馏研究与机理解释(一致性蒸馏因”端点投影/方差缩减”在校准上超过teacher,而Mean-Flow/flow-map在复合rollout下失败)。我们诚实的评测——自由rollout、相对MC预言机定价、带显式地板的RAW/CAL区分——揭示了一条贯穿全文的raw↔校准权衡,以及一类被单一校准数掩盖的假象。基础FM teacher仍是raw自洽冠军(0.475);调度采样给出最佳形状平衡(峰度4.41);我们的方法给出最佳校准定价;一致性蒸馏在不损失保真的前提下让模拟器变便宜。

展望。 (i)把恰当评分路径损失纳入teacher原生目标与检查点选择,同时瞄准低RAW与低CAL;(ii)实现多步一致性采样器;(iii)以架构改动(如对rollout施加注意力)直接攻击暴露偏差;(iv)以同一世界模型与评测协议迁移到真实限价订单簿与股票数据。

可复现性。 我们公开全部代码:路径损失微调(pathwise_teacher_combined.py)、三种蒸馏(distill_{consistency,mean_flow,flow_map}.py)、少步采样器(rollout_fewstep.py)、评测

(`rollout.py`, `evaluate_rollout.py`)、以及计量经济与扩散基线脚本。数据由 `generate_heston_data.py` (QE 格式, 种子 20260530) 与 `generate_mc_oracle.py` 重新生成。

参考文献

- [1] Michael S. Albergo and Eric Vanden-Eijnden. Building normalizing flows with stochastic interpolants. In *International Conference on Learning Representations (ICLR)*, 2023.
- [2] Eloi Alonso, Adam Jelley, Vincent Micheli, Anssi Kanervisto, Amos Storkey, Tim Pearce, and François Fleuret. Diffusion for world modeling: Visual details matter in atari. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [3] Leif B. G. Andersen. Simple and efficient simulation of the heston stochastic volatility model. *Journal of Computational Finance*, 11(3):1–42, 2008.
- [4] Samy Bengio, Oriol Vinyals, Navdeep Jaitly, and Noam Shazeer. Scheduled sampling for sequence prediction with recurrent neural networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.
- [5] Nicholas M. Boffi, Michael S. Albergo, and Eric Vanden-Eijnden. How to build a consistency model: Learning flow maps via self-distillation. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [6] Tim Bollerslev. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327, 1986.
- [7] Tim Bollerslev. A conditionally heteroskedastic time series model for speculative prices and rates of return. *The Review of Economics and Statistics*, 69(3):542–547, 1987.
- [8] Rama Cont. Empirical properties of asset returns: Stylized facts and statistical issues. *Quantitative Finance*, 1(2):223–236, 2001.
- [9] Zhengyang Geng, Mingyang Deng, Xingjian Bai, J. Zico Kolter, and Kaiming He. Mean flows for one-step generative modeling. *arXiv preprint arXiv:2505.13447*, 2025.
- [10] Lawrence R. Glosten, Ravi Jagannathan, and David E. Runkle. On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5):1779–1801, 1993.
- [11] Tilmann Gneiting and Adrian E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.

- [12] Georg M. Goerg. The lambert way to gaussianize heavy-tailed data with the inverse of tukey's h transformation as a special case. *The Scientific World Journal*, 2015:909231, 2015.
- [13] Arthur Gretton, Karsten M. Borgwardt, Malte J. Rasch, Bernhard Schölkopf, and Alexander Smola. A kernel two-sample test. *Journal of Machine Learning Research*, 13:723–773, 2012.
- [14] David Ha and Jürgen Schmidhuber. Recurrent world models facilitate policy evolution. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [15] Steven L. Heston. A closed-form solution for options with stochastic volatility with applications to bond and currency options. *The Review of Financial Studies*, 6(2):327–343, 1993.
- [16] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.
- [17] Zacharia Issa, Blanka Horvath, Maud Lemercier, and Cristopher Salvi. Non-adversarial training of neural sdes with signature kernel scores. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [18] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- [19] Hans R. Künsch. The jackknife and the bootstrap for general stationary observations. *The Annals of Statistics*, 17(3):1217–1241, 1989.
- [20] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.
- [21] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *International Conference on Learning Representations (ICLR)*, 2023.
- [22] Terry J. Lyons, Michael Caruana, and Thierry Lévy. *Differential Equations Driven by Rough Paths*. Springer, 2007.
- [23] Hao Ni, Lukasz Szpruch, Magnus Wiese, Shujian Liao, and Baoren Xiao. Conditional sig-wasserstein gans for time series generation. *arXiv preprint arXiv:2006.05421*, 2020.
- [24] Hao Ni, Lukasz Szpruch, Marc Sabate-Vidales, Baoren Xiao, Magnus Wiese, and Shujian Liao. Sig-wasserstein gans for time series generation. In *Proceedings of the Second ACM International Conference on AI in Finance (ICAIF)*, 2021.

- [25] Lorenzo Pacchiardi, Rilwan Adewoyin, Peter Dueben, and Ritabrata Dutta. Probabilistic forecasting with generative networks via scoring rule minimization. *Journal of Machine Learning Research*, 25:1–64, 2024.
- [26] Dimitris N. Politis and Joseph P. Romano. The stationary bootstrap. *Journal of the American Statistical Association*, 89(428):1303–1313, 1994.
- [27] Cristopher Salvi, Thomas Cass, James Foster, Terry Lyons, and Weixin Yang. The signature kernel is the solution of a goursat pde. *SIAM Journal on Mathematics of Data Science*, 3(3): 873–899, 2021.
- [28] Yang Song and Prafulla Dhariwal. Improved techniques for training consistency models. In *International Conference on Learning Representations (ICLR)*, 2024.
- [29] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. In *International Conference on Machine Learning (ICML)*, 2023.
- [30] Magnus Wiese, Robert Knobloch, Ralf Korn, and Peter Kretschmer. Quant gans: deep generation of financial time series. *Quantitative Finance*, 20(9):1419–1440, 2020.
- [31] Jinsung Yoon, Daniel Jarrett, and Mihaela van der Schaar. Time-series generative adversarial networks. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2019.