

从“建模与训练”之后的完整演讲稿

第 1 页：建模与训练

接下来进入建模与训练部分。我们的目标是构建一个可被区制动作驱动和金融世界模型，能够在自由 rollout 下生成长期、稳定的市场路径，并且生成路径在期权定价、峰度和路径分布上接近真实数据。后面所有设计，包括两阶段 pipeline、SIGMA 路径微调和蒸馏，都是围绕这个目标展开的，提出一套从可控世界模型、路径分布训练到少步蒸馏的完整生成 pipeline。。

第 2 页：两阶段、动作条件的 Flow Matching 世界模型

我们的第一个创新，是把 Flow Matching 组织成一个面向金融市场的两阶段、动作条件世界模型。模型不是直接生成下一期收益，而是先生成下一期方差，再在新方差条件下生成下一期收益。每一步的条件包括当前方差、上一期收益和当前区制动作，也就是正常、高波动或者崩盘。这样做符合 Heston 模型的因果结构：先有波动状态，再产生收益变化。模型从初始状态出发，自回归生成 252 步，形成一个交易年的完整市场路径。因此它不仅是单步预测器，而是能够被区制驱动并长期自由推演的世界模型。

第 3 页：Flow Matching 适应性

Flow Matching 适合本任务，是因为这里的单步条件分布是一维、连续、单峰的。相比 GAN，它不依赖对抗训练，可以避免模式崩塌和尾部压扁；相比扩散模型，它学习的是直线输运，ODE 轨迹近似仿射，少步积分误差更小。这个优势在长程 rollout 中尤其重要，因为每一步的小误差都会在 252 步复合中累积。也就是说，Flow Matching 的稳定采样结构，为后面的长期市场生成提供了基础。

第 4 页：Flow Matching 长时改进

基础 FM 仍然有训练和部署分布不一致的问题。训练时 teacher 使用真实上一期收益作为条件，但自由生成时，上一期收益来自模型自身，所以误差会不断累积。调度采样就是让模型在训练时以一定概率使用自己生成的上一期收益，从而缓解 exposure bias，让训练条件更接近自由 rollout 条件。LWFM 则是在收益上加入 Lambert-W 重尾变换，可以轻微提升峰度，让尾部更接近真实金融数据。不过这两个部分不是最终最核心的贡献：调度采样主要改善长程形状，LWFM 是尾部增强的探索性变体。

第 5 页：SIGMA 路径分布微调

本文最核心的训练创新是 SIGMA。它把可微 rollout 加入训练过程，并在自由生成出来的整条路径上施加严格恰当的路径分布分数，从而闭合单步训练目标和自由部署目标之间的缺口。也就是说，模型不再只学习“下一步像不像”，而是直接学习“完整生成路径像不像”。

SIGMA 主要由四个部分组成。第一是 Sig-MMD，用来约束时间结构和序列特征，比较生成路径和真实路径的整体形状。它的作用是让模型不仅匹配单点分布，还要匹配路径随时间展开的动态结构。第二是

Sig-W1，用来匹配一阶路径泛函均值，给签名特征提供一个更稳定、更低方差的均值约束。它可以帮助模型对齐那些由整条路径决定的统计量，而不是只对齐局部收益。第三是 Energy score，用来约束幅度和联合尺度，防止模型生成的路径整体尺度漂移。金融定价对收益尺度和终端方差非常敏感，所以这一项可以避免“形状像但数值尺度不对”的情况。第四是 Lmoment，用来锁定定价主导矩，包括低阶矩、终端方差、绝对收益和峰度。它直接针对期权定价最敏感的统计量，使路径微调能够服务于金融目标。

这几个部分的组合逻辑是：时间结构、一阶路径泛函、幅度尺度和定价矩同时约束。单独使用任何一个分数都不够，因为只看路径形状可能会丢失尺度，只看矩又会丢失时间结构。SIGMA 的作用就是把这些互补信息放到同一个可微自由 rollout 训练框架里，使模型直接优化部署时真正生成的路径分布。这也是它能够显著改善校准定价的原因。

第 6 页：蒸馏

teacher 的 rollout 成本比较高，因为每一步都需要多步 ODE 采样，而我们又要生成 252 步。因此我们把 teacher 蒸馏为一步或少步学生模型。这里比较了一致性蒸馏 CD、Mean-Flow 和 Lagrangian flow-map。我们这部分的贡献，是给出了金融长程复合场景下的系统评测和机理解释。CD 学习一步输出沿 teacher ODE 保持终点一致，可以减少采样噪声和离散误差累积；Mean-Flow 在重尾和强状态依赖下容易退化或爆炸；flow-map 支持 K 步复合，但对步数敏感，不同指标的最优点不同。

第 7 页：主结果

接下来看主结果。这里的基线含金量比较高：Quant-GAN 代表金融时间序列生成里的 GAN 方法，GARCH-t 是经典计量经济学波动率基线，DDPM 是同架构扩散对照，用来说明为什么选择 FM，块自助法接近数据回放，作为参照但不可控。

从结果看，基础 FM teacher 在未校准的原始定价误差，也就是 raw 指标上最佳，达到 0.475，并且 raw 和校准后的 cal 比较接近，说明它的内在生成质量高，不是靠后处理校准修出来的。因此它最适合作为长期自由推演的市场模拟器。缺点是峰度略低，尾部不够厚。

FM 加调度采样后，峰度更接近真实值，说明 exposure bias 被缓解，路径形状更真实，但 raw 会有所上升。这说明它是一个形状更平衡的工作点。

SIGMA-Pin 的校准定价最优，cal 达到 0.180，说明路径分布分数和矩约束确实把模型能力集中到了定价主导统计量上。但它的 raw 变差，说明它牺牲了一部分自由生成的自治性。这正好揭示了全文主线：raw 自治性和校准定价之间存在权衡。其他基线的问题也很清楚：Quant-GAN 对抗训练不稳定，DDPM 长程复合误差更大，GARCH-t 峰度过高且不可控，所以都不如我们的世界模型框架适合这个任务。

第 8 页：FM 模型的表现

这一页主要把 FM 系列模型单独拿出来看。基础 FM teacher 的特点是未校准表现最强，说明两阶段 Flow Matching 在自由 rollout 下确实能够保持较好的内在自治性，这是整个 pipeline 成立的基础。FM

加调度采样之后，重点不是追求最低 raw，而是改善长程生成中的路径形状，特别是峰度更接近真实市场，这和 PPT 中强调的“缓解 exposure bias”是一致的。

进一步看，进阶 FM 作为 SIGMA 的基座，本身不是最终校准冠军，但它提供了更稳定的训练起点。SIGMA-Base 和 SIGMA-Pin 则是在这个基座上进一步加入路径分布微调，其中 SIGMA-Pin 通过更强的矩和锚定约束，把校准定价推进到训练阶段最好。也就是说，这一页想表达的是 FM 家族内部的递进关系：基础 FM 提供稳定自由生成，调度采样改善长程形状，SIGMA 再把完整路径分布和金融定价目标进一步对齐。

第 9 页：路径分布损失消融

消融实验验证了 SIGMA 的设计。仅使用 Sig-MMD 或 Sig-W1，可以对齐部分路径结构，但幅度可能漂移，导致定价崩坏；仅使用 Energy 或矩项，可以控制尺度或定价相关统计量，但时间结构约束不足。组合严格恰当分数同时约束时间结构、幅度尺度和定价主导矩，所以效果最稳定，并且超过对抗式 WGAN-GP 判别器。这说明 SIGMA 不是简单堆 loss，而是针对金融路径真实性的不同维度做互补约束。

第 10 页：一步蒸馏结果对比

蒸馏结果里最重要的现象是，CD 可以在 cal 指标上超过 teacher。原因是 teacher 每一步都要进行多步 ODE 采样，采样噪声和离散误差会在 252 步中累积，最终影响终端方差，而期权定价又高度依赖终端方差。CD 把多步采样压缩成一步端点映射，减少噪声累积，使终端方差更干净，所以定价更准确。

例如 SIGMA-Base 经 CD 后，cal 降到 0.170，仍高于真实测试集地板 0.165，所以可以认为是真实提升，而不是明显校准假象。当然，CD 也有代价：它会压平一部分尾部，使峰度下降。这说明 cal 的提升部分来自方差缩减，代价是牺牲部分尾部真实性。Mean-Flow 失败或爆炸，flow-map 指标敏感，则说明不是所有少步方法都适合金融长程 rollout。CD 成功的关键，是它和 FM 的近仿射 ODE 结构更匹配。

第 11 页：少步 flow-map NFE 扫描

flow-map 的 NFE 扫描说明，复合步数不是越多越好。K 等于 1、2、4、8 时，不同指标的最优点不同：raw 可能在 K=2 最好，cal 可能在 K=1 最好，而峰度会随着步数增加膨胀。这说明每一步映射的小偏差在复合后可能放大尾部误差，反而损害生成质量。因此，少步采样需要在 raw、cal 和尾部之间做权衡。相比之下，CD 的一步端点映射更稳定，更适合这个长程金融生成任务。

第 12 页：核心结果

最后总结一下。全文最核心的结论是：raw 自治性和校准定价之间存在系统权衡。基础 FM teacher 的 raw 最好，说明它自由 rollout 最稳定；FM 加调度采样牺牲一点 raw，但换来更好的峰度和路径形状；SIGMA 和一致性蒸馏则把能力集中到终端方差和定价主导矩上，所以校准定价最好，但会损失一部分路径级真实性。

方法上的启示是：Flow Matching 的直线输运适合长程 rollout；两阶段方差—收益 pipeline 让模型符合金融因果结构并具备区制控制能力；SIGMA 用严格恰当路径分数替代对抗判别器，能更直接优化自由生成路径；一致性蒸馏通过端点投影和方差缩减降低采样误差，因此可以在 cal 上超过 teacher。

更进一步，这个实验也说明，金融生成模型的好坏不能只由一个指标决定。面向不同使用场景，模型选择也不同：如果重视长期自由推演，基础 FM 更合适；如果重视路径形状和尾部特征，调度采样是更平衡的选择；如果重视接入市场统计量之后的定价精度，SIGMA 和一致性蒸馏更有优势。

最后强调一下我们工作的定位。已有的金融时间序列生成方法，包括 Quant-GAN 这类对抗式生成模型、GARCH-t 这类经典波动率模型，以及扩散模型，都能从不同角度处理市场路径生成问题。我们与这种经典方法的效果作对比，针对区制切换 Heston 市场路径生成与期权定价评测这个任务，提出了一套完整的新 pipeline：第一，用两阶段、动作条件的 Flow Matching 建立可控世界模型；第二，用 SIGMA 把签名、能量和矩匹配加入可微自由 rollout，直接优化整条生成路径；第三，系统评测少步蒸馏在金融长程复合场景下的效果和机理。总体来说，我们提出的是一个可控、自治、金融保真的市场生成框架，也给出了一套更诚实的金融生成评测方式。以上就是我们的主要工作，谢谢大家。

raw：可以翻译成未校准结果、原始生成结果，或者在演讲里说成原始定价误差。

含义是：直接使用生成模型输出的收益路径去计算期权价格，不做额外的均值、方差修正。它衡量的是模型本身自由生成路径的内在质量。

cal：可以翻译成校准后结果、校准定价误差。

含义是：先对生成收益做一次仿射矩校准，也就是把生成收益的均值和标准差调整到训练数据对应的均值和标准差，再去计算期权价格。它更接近“接入市场统计量之后”的定价表现。

演讲里建议统一说：

raw 表示未校准的原始定价误差，衡量模型本身的自由生成能力；cal 表示做过一次矩校准之后的定价误差，更接近接入市场统计量后的实用定价表现。